# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

## 개요

- **진행기관 / 소속**
  - SSAC 서울특별시 영상처리를 위한 인공지능 개발자 과정
- **프로젝트 수행 기간**
  - 2021. 12. (4주)
- **프로젝트 인원 (기여도)**
  - 1명 (100%)
- **사용 Tool (Python)**
  - Scikit learn, Numpy, Pandas, Matplotlib, Seaborn
- **프로젝트 주제**
  - 대출 연체 리스크를 관리하기 위한 인사이트 도출
- **목표**
  - 대출 연체 가능성 여부를 예측하는 알고리즘 모델

# 카드 데이터를 활용한 고객의 니즈 파악 및 홍보채널 발굴하기

## 프로젝트 개요

- **결측치 및 이상치 처리**
  - IQR기준 이상치 행 삭제
  - 결측치 평균값으로 대체
  - 독립변수와 집단 간 관계 확인
  - 상관관계 확인

- **스케일링**
  - 결측치
  - 결측치 및 이상치 처리

- **목표**
  - 비선형모델(트리계열)에 사용하기 위해 Label Encoding
    트리계열 모델링 Holdout(Stratify=y), stratifiedKFold
  - DecisionTreeClassifier, RandomForest, GradientBoostingClassifier, AdaboostClassifier, BaggingClassifier, xgboostClassifier, lightgbm, ExtraTreesClassifier

- **모델 해석**
  - Target Plot, Prediction Plot, PDP, ICE, SHAP

# 대출 대상자 중 2년 내 대출금을 90일 이상 연체할 가능성이 있는지 여부를 예측하는 알고리즘 모델링

## 과정

- 독립변수와 집단 간 관계 확인

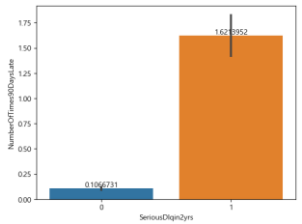


t-test p-value 기준 독립변수 별
종속변수(연체, 미연체) 집단 간 차이 확인

-2년 이내에 연체 여부 기록이 존재하는 사람들의 경우
연체 집단과 미연체 집단간 차이 존재

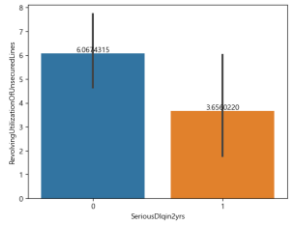


-부동산과 할부 부채를 제외한 보유 자산 및 신용 대비
현재 운용가능한 돈의 비율 대상
연체 집단과 미연체 집단 간 차이 없음

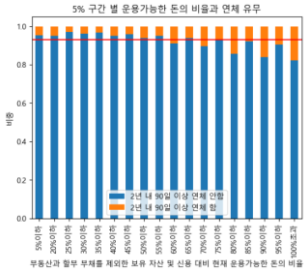


| | | |
|---|---|---|
| | No | 0.930502 | 0.069498 |
| | Yes | 0.939394 | 0.060606 |

카이제곱 검정 p-value 기준 독립변수 별
종속변수(연체, 미연체) 집단 간 차이 확인

-5% 구간 별 운용가능한 돈의 비율과 연체 유무
-> 운용가능한 돈 비율과 연체 여부는 관계가 존재하며
의외로 운용가능한 돈의 비율이 낮은 편이
연체비율이 더 낮은 경향을 보임

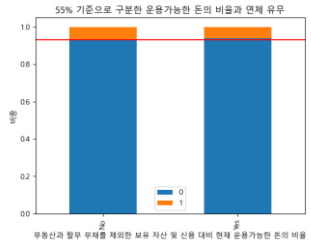


-평균을 넘는 돈의 비율은 55이상 60%이하부터 연체비율이
높아지는 경향이 생겨 55%초과와 이하로 변수를 새로 생성해
집단간 차이 확인
-> 연체 집단과 미연체 집단 간 차이가 없어 파생변수를
추가적으로 생성하지 않고 진행

## 과정

- 변수들 간 상관관계 확인

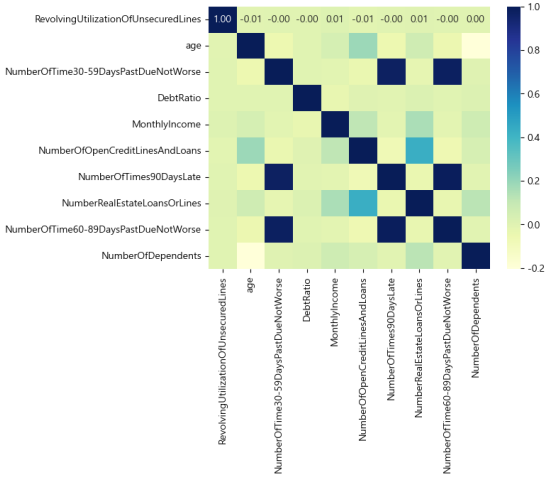


강한 수준 상관관계를 보이는
독립변수들이 존재해
다중공선성을 확인해본 결과
3개의 변수에서 10을 넘는 VIF를 보임.

-> 이번 프로젝트에서는 모든 변수들의
종속변수에 대한 모델 영향력을 확인하는
것을 목적으로 하기 때문에 트리기반
모델을 주로 고려해 모델링 진행

- 상관관계 확인

**강한 수준 상관관계**

최근 2년 내 30일에서 59일 간 연체횟수
과거 90일 이상 연체한 횟수

최근 2년 내 30일에서 59일 간 연체횟수
최근 2년 내 60일에서 89일 간 연체횟수

과거 90일 이상 연체한 횟수
최근 2년 내 60일에서 89일 간 연체횟수

**중간 수준 상관관계**

할부 대출과 신용 대출을 빌린 횟수
주택 담보 및 부동산 담보 대출 건수

**그 외 변수들**

신용한도 총합 대비 신용카드 및
개인신용 대출 총 잔액의 비율

대출자 나이

전체 수입 대비 월 부채 상환과 월 지출

월 수입

대출자를 제외한 부양가족 수

**상관관계는 선형기준으로 봐서 비선형 관계까지 확인해볼 필요가 있다고 생각해 PDP(Partial dependence plots), ICE Plot을 활용해 해석.**

# 대출 대상자 중 2년 내 대출금을 90일 이상 연체할 가능성이 있는지 여부를 예측하는 알고리즘 모델링

## 과정

- Roc-Auc score 기준 베이스라인 모델 정의

| | |
|---|---|
| AdaboostClassifier | 0.854669 |
| xgboostClassifier | 0.846333 |
| GradientBoostingClassifier | 0.833166 |
| RandomForest | 0.827248 |
| BaggingClassifier | 0.771623 |
| DecisionTreeClassifier | 0.607134 |
| ExtraTreesClassifier | 0.606956 |
| KNN_standardscale | 0.686000 |

➡ **Roc-Auc score가 80%를 넘는 모델을 기준으로 베이스라인 모델 선정.**

- 베이스라인 모델 최적화

RandomSearchCV
- learning_rate
- n_estimators
- max_depth
- subsample
- min_split_loss
- cosample_bytree

GridSearchCV ⇨

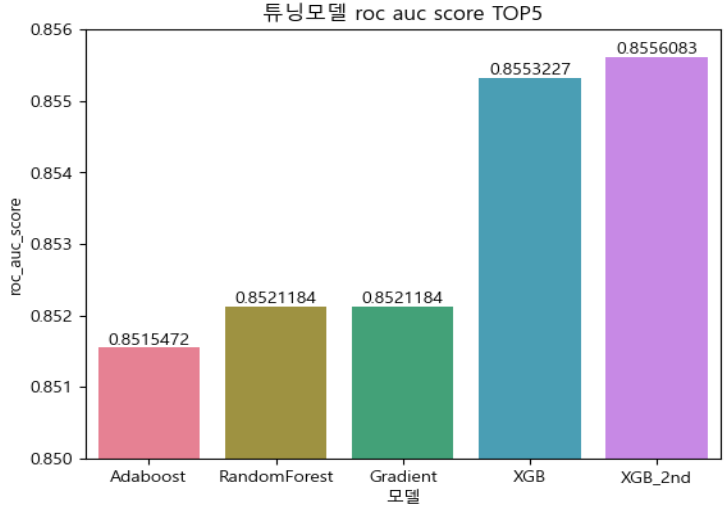


## 과정

- Votingclassifier(Soft voting)
- XGB모델의 과적합을 우려해 voting 수행

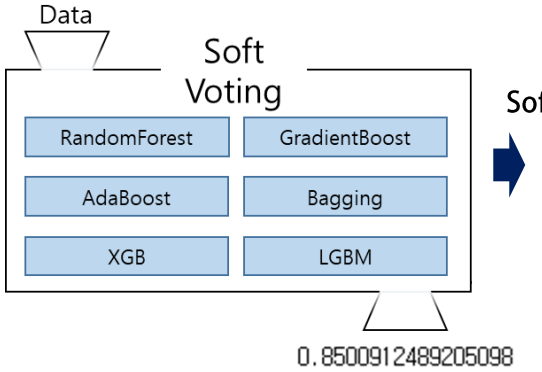


Soft voting을 진행했으나 xgb 성능 우세.

➡ Voting 을 사용할 경우 성능 개선폭이 크지 않고 모델 복잡도만 증가시켜 큰 효과가 없을 것이라 보고 최적화 한 XGBclassifier 모델을 사용하는 것이 효과적이라고 판단

- Tree 기반 변수중요도 확인

| index | | 변수중요도 |
|---|---|---|
| 6 | 과거 90일 이상 연체한 횟수 | 0.370254 |
| 0 | 신용카드 및 신용 한도 내에서 빌린 대출금의 총 잔액을 신용 한도 합계로 나눈 값(... | 0.178098 |
| 2 | 최근 2년간 30일에서 59일 사이에 연체한 횟수 | 0.169491 |
| 8 | 최근 2년간 60~89일 연체한 횟수 | 0.138153 |
| 7 | 주택 담보 대출을 포함한 부동산 담보대출 건수 | 0.029241 |
| 1 | 대출자의 나이 | 0.028092 |
| 5 | 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 ... | 0.027488 |
| 3 | 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 값 | 0.025118 |
| 4 | 월 수입 | 0.019162 |
| 9 | 대출자를 제외한 부양가족 수 | 0.014905 |

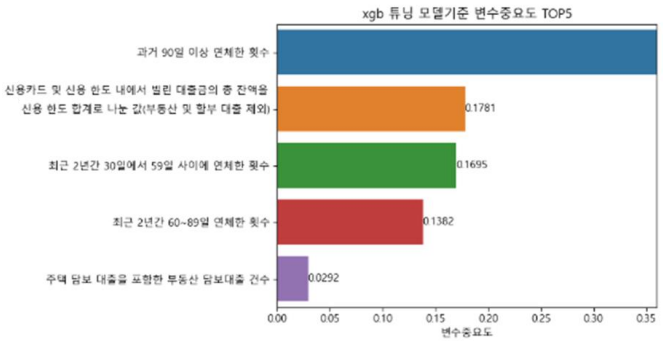


➡ **과거 90일 이상 연체 횟수와 신용한도 총합 대비 신용카드 및 개인신용 대출 총 잔액의 비율이 2년내 90일 이상 연체 여부를 판단하는데 중요한 변수로 작용.**
**상위 3개의 변수가 연체 기간과 관련되어 있음.**

# 대출 대상자 중 2년 내 대출금을 90일 이상 연체할 가능성이 있는지 여부를 예측하는 알고리즘 모델링

## 과정

- RFE(Recursive Feature Elimination)기반 변수중요도 확인

```
RFE 결과
( 3) NumberOfTimes90DaysLate          0.431330
( 2) NumberOfTime30-59DaysPastDueNotWorse 0.202259
( 5) NumberOfTime60-89DaysPastDueNotWorse 0.177621
( 1) RevolvingUtilizationOfUnsecuredLines 0.156073
( 4) NumberRealEstateLoansOrLines     0.032716
```

➡ Xgb모델로 인한 과적합을 우려해 rfe로도 변수중요도 확인결과
상위 4개 변수가 Tree 변수중요도를 기준으로 산출한 중요변수와 동일

- 모델해석

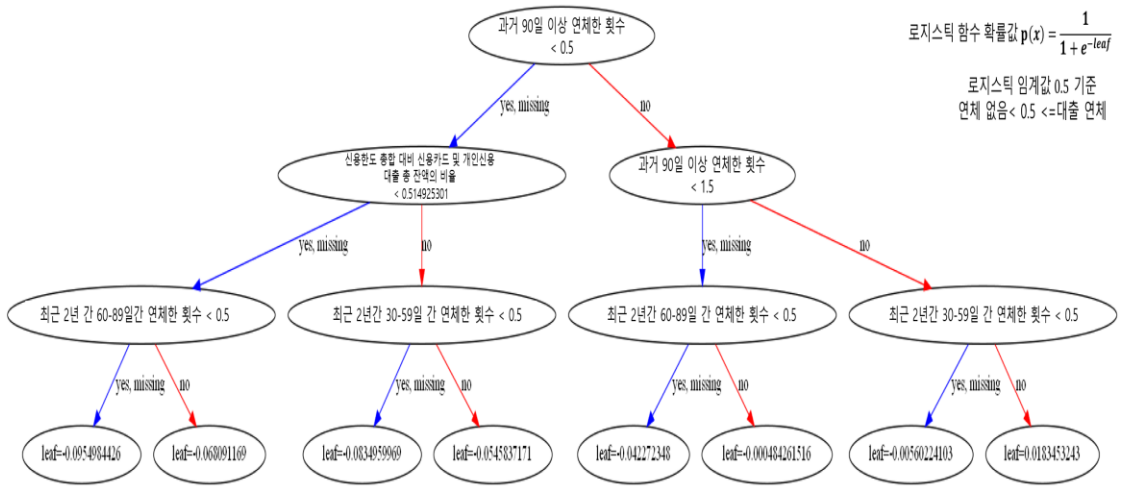


로지스틱 함수 확률값 $p(x) = \frac{1}{1+e^{-leaf}}$

로지스틱 임계값 0.5 기준
연체 없음< 0.5 <=대출 연체

➡ 신용한도 총합 대비 신용카드 및 개인신용 대출 총 잔액의 비율,
최근 2년간 기간별 연체한 횟수(90, 30-59, 60-89) 데이터를
보유했다면 대출 연체 판단 가능

과거 연체한 기록이 없는 신규 고객의 경우 현재의 판별 기준을 도입하기 어려움.
지금의 판별 기준은 기존에 보유한 대출상품을 자사의 보험상품으로 변경하고자
할 때 활용하는 것이 적절

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

## Dependence plot으로 상관관계 확인

- 30~59일 연체한 횟수, 90일 이상 연체한 횟수 간 상관관계 확인

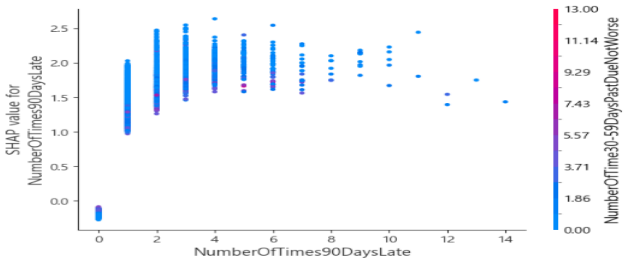


- 90일 이상 연체 횟수가 늘어날수록 대출 연체 가능성 상승
- 90일 이상 연체횟수가 1 이상이면 대출 가능성 급격히 상승
- 1회에서 2회로 넘어갈 때도 급격히 대출 가능성 상승.

→ **90일 이상 연체 횟수가 1 이상일 때 위험군으로 분류하고 리스크를 관리할 필요가 있음.**

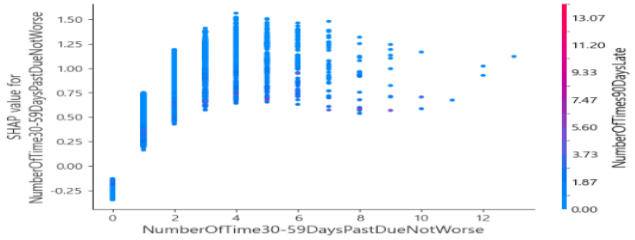


- 90일 이상 연체 횟수가 늘어나며 매 구간마다 30-59일 연체 횟수가 5번 이상인 케이스 존재
- 9일 이상 횟수가 늘어나도 30-59일 연체 횟수가 많으면 오히려 연체 가능성이 비교적 낮아지는 것을 발견.

→ **30~59일 연체가 많다는 것은 단기 연체가 반복되었다는 것을 의미**

→ **반복적으로 단기 연체가 늘어나는 것은 갚으려 하지만 재정적으로 불안정한 상태인 것으로 추측**

→ **금융기관에서는 30~59일 연체 횟수가 많아도 결국은 상환할 고객일 가능성이 크기 때문에 상환 능력이 전혀 없는 것은 아닌 상태로 간주하고 신용 점수를 많이 하락 시키는 것은 지양**

→ **다만 30~59일 연체 횟수가 적어도 90일 이상 연체 횟수가 많은 고객은 연체 후 끝까지 갚지 않는 고객으로 간주하고 장기 연체자로 구분하는 것이 적합해 보임**

→ **연체 횟수와 연체 후 상환 여부를 포함해 연체 패턴을 분석하고 끝까지 갚는 고객과 갚지 않는 고객으로 구분해 신용 점수 조정 및 리스크 관리에 활용**

- 30~59일 연체한 횟수, 60~89일 연체한 횟수 간 상관관계 확인

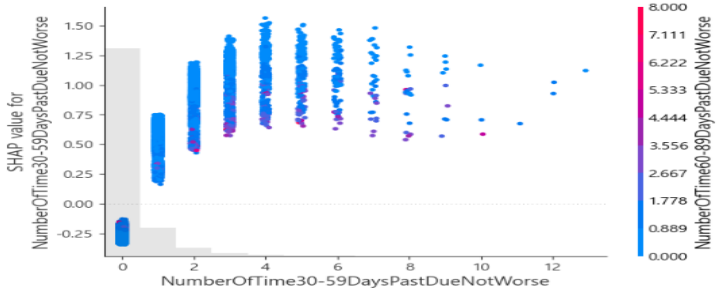


- 30~59일 연체 횟수가 늘어나면 4회까지 연체 가능성 급격히 상승
  → **30~59일 연체 횟수가 1 이상일 때 위험군으로 분류하고 리스크를 관리 할 필요가 있음**
  → **또한 4회까지 횟수별 고객에 따라 리스크 관리를 고민해볼 필요가 있어 보임**

- 30~59일 연체가 많아지며 60~89일 연체도 증가하는 추세지만, 60~89일 값이 크면 shap 값이 낮아지는 경향 존재
  → **60~89일 연체 횟수가 늘어나는 만큼 단기인 30-59일 연체 횟수도 늘어나는 것으로 추측**
  → **60~89일 연체 횟수가 일정 횟수 이상이면 모델이 연체 위험도를 덜 높게 평가할 가능성 존재**

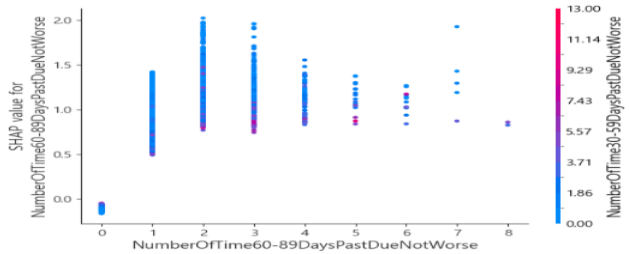


- 1회부터 2회까지 60~89일 연체 횟수가 늘어날 수록 연체 가능성이 급격히 상승
  → **연체 횟수를 늘리지 않기 위한 정책을 고민해볼 필요가 있음**

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- **Dependence plot으로 상관관계 확인**
  - 60~89일 연체한 횟수, 90일 이상 연체한 횟수 간 상관관계 확인

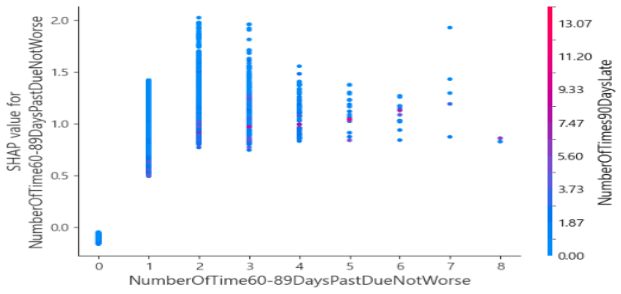


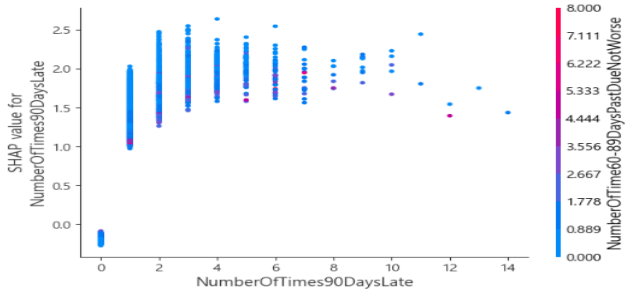


- 60~89일 이상 연체 횟수가 늘어날수록 3회까지 연체 가능성 상승
- 60~89일 이상 연체횟수가 1 이상이면 대출 가능성 급격히 상승
- 1회에서 2회로 넘어갈 때도 급격히 대출 가능성 상승

  → **60~89일 연체 횟수가 1 이상일 때 위험군으로 분류하고 리스크 관리 필요**

- 60-89일 연체 횟수가 늘어날 때 4까지 90일 이상 연체 횟수가 클 경우 연체 가능성이 낮아지는 케이스 존재.

  → **60-89일 연체 횟수가 5 이상일 경우 갚으려는 의지가 있지만 60-89일 연체 횟수보다 90일 연체가 더 많아 의지가 있어도 연체를 갚을 수 있는 능력이 부족한 것으로** 보임

- 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 빌린 횟수, 주택 담보 대출을 포함한 부동산 담보 대출 건수

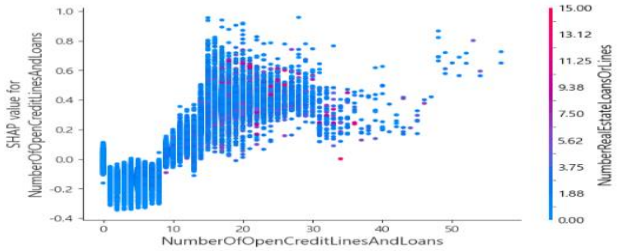

- 할부 대출 및 신용 대출을 빌린 횟수가 0일 때 shap 값은 0에 가까워, 해당 변수가 모델에 미치는 영향은 작다고 간주
- 할부 대출 및 신용 대출을 빌린 횟수가 1 이상 10 미만일 때, 부동산 담보대출도 적으며 연체 가능성이 낮아짐
- 할부 대출 및 신용 대출을 빌린 횟수가 10 이상 20 이하일 때, 대출 연체가능성이 급격히 상승

  → **할부 대출 및 신용 대출을 빌린 횟수가 10 미만일 때와 10 이상일 때로 나누어 리스크를 관리할 필요가 있음**

- 부동산 담보 대출 3 이상부터 급격히 대출 연체 가능성이 늘어남.
- 부동산 담보 대출이 많을수록 신용 대출건수도 늘어나는 경향 존재.
- 부동산 담보 대출이 2일때에서 3으로 넘어갈 때 및 부동산 담보 대출이 4에서 5로 넘어갈 때,부동산 담보 대출이 11에서 12로 넘어갈 때 급격히 연체 가능성 상승.
- 부동산 담보 대출이 늘어나고 할부 대출 및 신용 대출 건수도 늘어나면서 연체 가능성이 늘어나는 경향 존재

  → **부동산 대출 3~4건, 5~9건 구간으로 나눠 리스크를 관리해볼 수 있을 듯 함.**

  → **부동산 대출과 할부 대출 및 신용 대출이 결합될 때 리스크가 커짐. 리스크 관리를 위해 금리 인상이나 대출 한도 조정, 신용 평가 강화 등을 고려해 볼 수 있음.**

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

## ● 상관관계가 있어 보이는 변수 추가 확인

- 30-59일 연체 횟수와 신용한도 총합 신용한도 총합 대비 신용카드 및 개인신용 대출 총 잔액의 비율 간 상관관계 확인

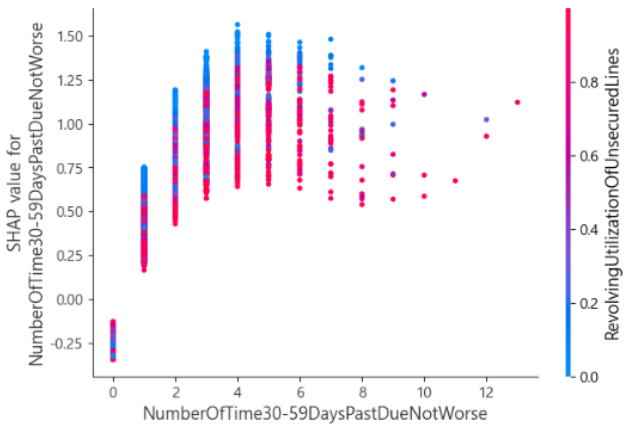


- 30-59일 연체 횟수가 1 이상일 때 신용한도 총합 대비 신용 대출의 비율이 높으면 연체 가능성이 낮아짐
  - → **30~59일 연체 경험이 있을 때 신용한도를 많이 쓴 사람들의 경우 연체 가능성이 떨어진다는 것은 신용카드를 불법적으로 현금화하는 사람들이 아닌지 추측.**
  - → **따라서 신용 대출의 비율이 0.5이상인 사람들을 대상으로 연체율을 계산하고 추가 분석을 진행해 볼 필요가 있음.**

- 90일 이상 대출 연체 횟수와 신용한도 총합 대비 신용카드 및 개인신용 대출 총 잔액의 비율 간 상관관계 확인

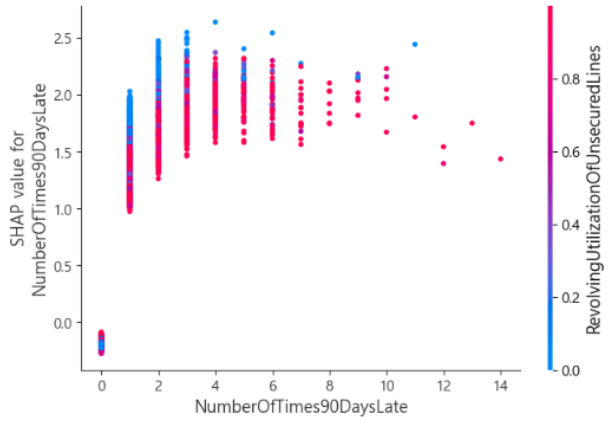


- 90일 이상 연체 횟수가 1 이상일 때 신용한도 총합 대비 신용 대출의 비율이 높으면 연체 가능성이 낮아지는 경향 존재
  - → **30~59일과 마찬가지로 신용카드를 불법적으로 현금화하는 사람들로 의심하고 추가 분석을 진행해 볼 필요가 있음**

- 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 빌린 횟수와 신용한도 총합 대비 신용카드 및 개인신용 대출 총 잔액의 비율 간 상관관계 확인

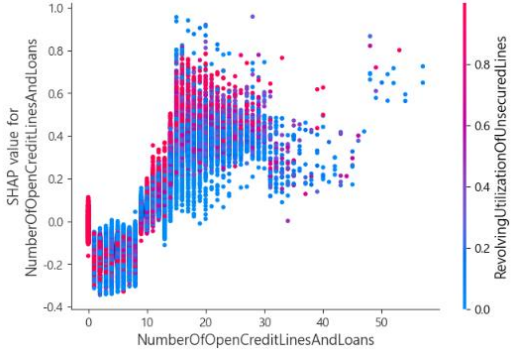


- 할부 대출 및 신용 대출 건수가 0일 때 신용한도 총합 대비 신용 대출의 비율은 대체로 높게 나타남.
- 할부 대출 및 신용 대출 건수가 없을 때 shap 값은 0에 가까워 해당 변수가 모델에 미치는 영향은 작은 것으로 보임.
- 신용 대출 건수가 1 이상 10 이하라면 신용한도 총합 대비 신용 대출의 비율이 미치는 영향은 작은 것으로 보이며 해당 값이 존재해도 대출 연체 가능성이 낮아지는 경향이 있음.

- 할부 대출 및 신용 대출 건수가 10 이상 20 이하일 때 연체 가능성이 급격히 상승.
- 또한 할부 및 신용대출 건수가 10 이상일 때 신용한도 총합 대비 신용 대출의 비율이 높을 때 연체 가능성이 높아짐.
  - → **할부 대출 및 신용 대출 건수가 10 이상이면 추가적으로 심사를 강화할 필요가 있음.**
  - → **할부 대출 및 신용 대출 건수가 10 이상일 때 신용한도 총합 대비 신용 대출의 비율이 높으면 연체 가능성이 더욱 높아지는 경향이 있어 두 변수를 결합한 리스크 관리 체계가 필요**

- 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 빌린 횟수와 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율 간 상관관계 확인
  - 할부 대출 및 신용 대출이 10 이상이고 월 지출 비율이 높을 때 연체 가능성 상승
    - → **할부 대출 및 신용 대출 건수가 10 이상이면 월 지출 비율이 0.4이상일 때 연체율을 고려해 해당 고객을 고위험군으로 분류한 뒤 추가적으로 심사를 강화할 필요가 있음**

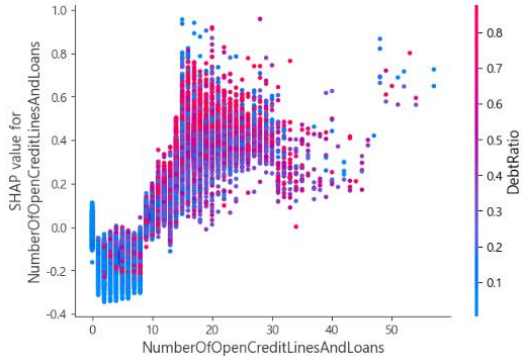

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 빌린 횟수와 대출자의 나이 간 상관관계 확인

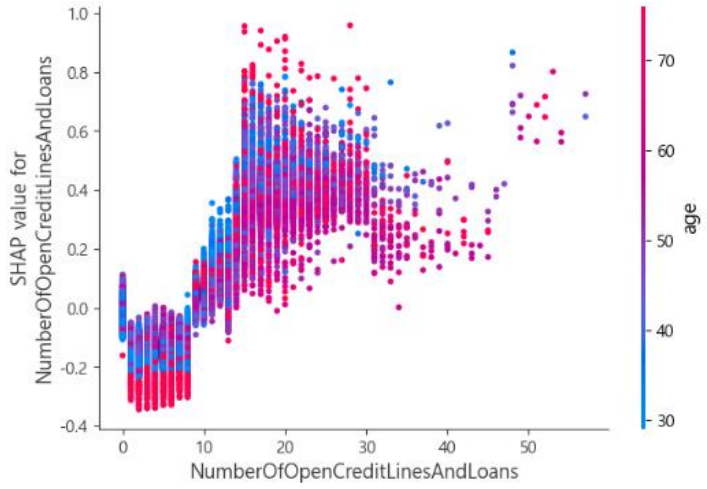


- 할부 대출 및 신용 대출 건수가 1 이상 10 이하일 때 대출자의 나이가 50 이상이라면 연체 가능성이 낮아지는 경향이 있음.

→ **대출자가 50세 이상일 때 할부 대출 및 신용 대출 건수가 많아도 10 미만이라면 연체 가능성이 낮은 편이기 때문에 우량고객일 가능성이 있음.**

→ **해당 조건에 해당하는 고객 중 대출 여력이 있는 사람을 구분하고 관심 있는 대출 상품을 제시해 볼 수 있을 듯함.**

- 주택 담보 대출을 포함한 부동산 담보 대출 건수와 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율 간 상관관계

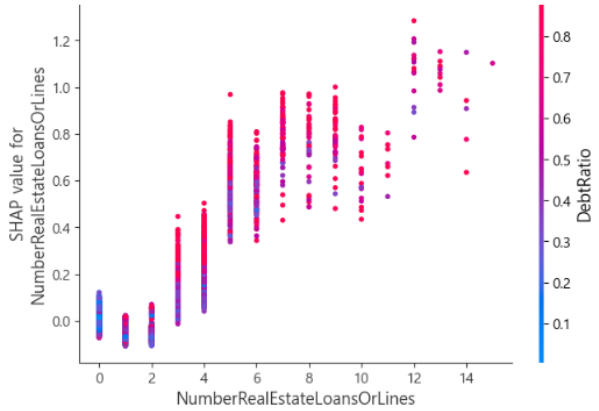


- 부동산 담보 대출이 늘어날 수록 연체 가능성이 높아짐.
- 부동산 담보 대출건수 3~4, 5~6, 7~9 횟수별로 구간을 나눠볼 수 있을 듯함.
- 부동산 담보 대출 횟수가 많아지고 월 지출 비율이 높아질수록 연체 가능성이 늘어남.
- 부동산 담보 대출을 보유하고 있을 때 대부분의 고객들은 월 지출 비율이 0.5(50%) 이상인 것으로 나타남.
- 부동산 담보 대출 횟수가 3~4개일 때 월 지출 비율이 0.4~0.5라면 shap 값이 0에 가까움

→ **부동산 담보 대출 건수 3~4, 5~6, 7~9로 나눠 리스크를 분석해 볼 필요가 있음.**

→ **대출 횟수가 많고 월 지출 비율이 높다면 연체 위험이 클 가능성이 높기 때문에 대출 심사 시 이를 함께 고려하는 것이 필요.**

→ **전체적으로 월 지출이 50% 이상으로 고객들의 부동산 담보 부채 부담이 높은 것으로 보임. 여러 부동산 대출을 감당할 수 있다면 우량고객일 수 있다고 판단.**

→ **부동산 대출 횟수가 3~4일 때 월 지출 비율이 0.4~0.5인 고객들을 대상으로 연체율을 확인해 연체율이 낮다면 신용 우량 고객으로 분류하는 것을 검토.**

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 주택 담보 대출을 포함한 부동산 담보 대출 건수와 월 수입 간 상관관계

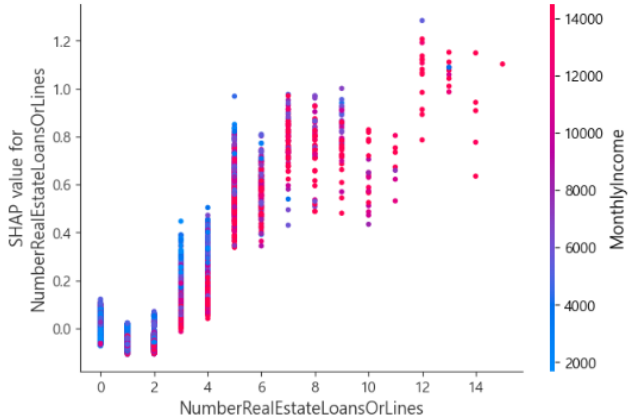


- 부동산 담보 대출 건수가 늘어날 때 월 수입이 늘어나면 대출 연체 가능성이 늘어남
  - → **부동산 담보 대출이 많은 고소득직에서도 연체 위험성이 증가하는 케이스가 다수 존재.**
  - → **부동산 담보 대출 건수가 3~4일 때 위험고객 심사 대상으로 보고 5 이상일 경우 위험고객으로 간주해 추가 분석해 볼 필요가 있음.**

  Ex) 부동산 대출이 많은 고소득자 그룹 중 연체율이 높은 고객과 낮은 고객 간 비교 분석

- 최근 2년 간 60~89일 연체한 횟수와 부동산 및 할부대출을 제외한 신용한도 내로 받은 융자의 총 잔액을 신용 한도 합계로 나눈 비율 간 상관관계 확인

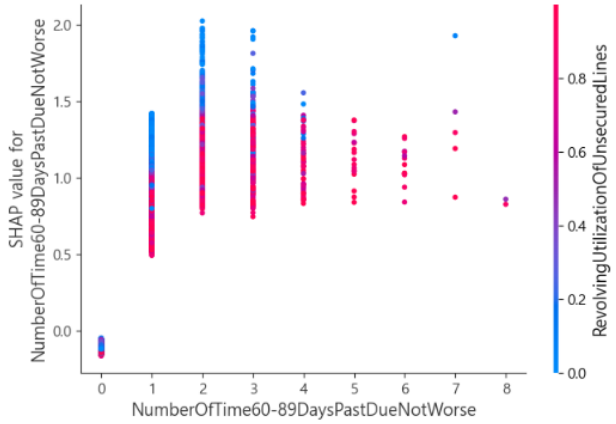


- 60~89일 연체 횟수가 1회 이상일 때 급격히 연체 가능성이 늘어나며 운용가능한 돈의 비율이 높을 때 연체 가능성이 낮아짐.
  - → **60~89일 연체 횟수가 1회 이상 3회 이하일 때 신용한도 총합 대비 신용 대출의 비율이 낮은 고객은 심사 시 특히 주의할 필요가 있음.**

## 약한 상관관계를 가지는 변수 해석

- 부동산 및 할부대출을 제외한 신용한도 내로 받은 융자의 총 잔액을
- 신용 한도 합계로 나눈 비율

**목표 플롯(Target plot)**

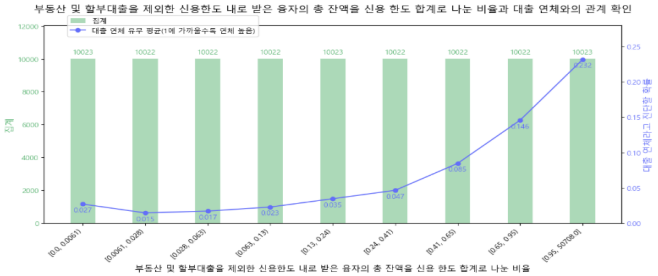


→ **각 구간별 대출 연체 확률은 신용한도 총합 대비 신용 대출의 비율이 24% 이상일 때부터 급격히 대출 연체 확률 상승.**

**예측 분포 플롯(Prediction distribution plot)**

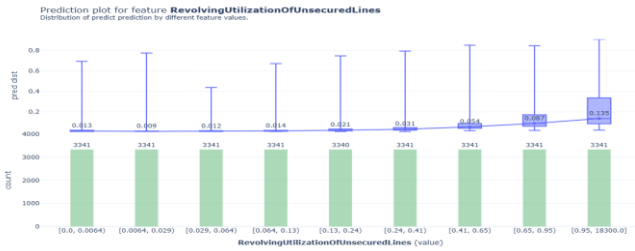


→ 예측모델은 학습 데이터와 비슷한 추이로 예측해 실제 데이터 패턴을 잘 학습한 것으로 추정.

→ 상단의 목표 플롯에 나온 구간별 확률과 캔들 스틱 차트로 모델 예측 결과 확률을 비교했을 때 대출 연체라고 판단할 가능성이 낮아져 신용한도 총합 대비 신용 대출의 비율 변수는 대출 연체를 하는데 구간 전체적으로 더 낮은 확률을 보임.

→ 모델에서는 해당 변수의 비율을 기준으로 덜 엄격하게 대출 연체 예측.

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

**모델 부분 의존성 플롯(Partial Dependence Plot 이하 PDP) (~10 (1000%))**

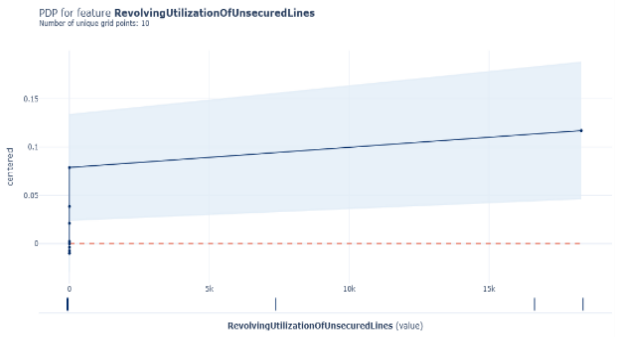


- 신용한도 총합 대비 신용 대출의 비율이 높아지면서 1(100%)까지 급격하게 대출 연체 확률 상승.

→ **특히 1 이상일 때 신뢰구간이 넓어지며 다른 변화를 보이지 않으나 이 구간부터는 신뢰도가 낮아져 추가적인 데이터 수집 필요.**

**PDP (~1.5(150%))**

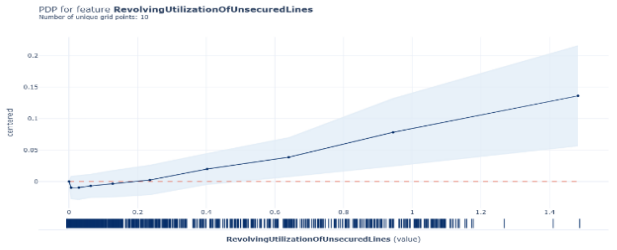


- 신용한도 총합 대비 신용 대출의 비율이 높아지면서 1(100%)까지 급격하게 대출 연체 확률 상승.
- 0.4(40%)부터 1(100%)까지 급격한 증가세를 보여 대출 연체 위험성이 커짐을 확인.

→ **대출 심사에서 신용한도 총합 대비 신용 대출의 비율이 0.4(40%) 이상일 경우 구간을 나눠 주의 깊게 평가할 필요가 있음.**

- 신용한도 총합 대비 신용 대출의 비율이 0.2(20%) 이하일 경우 대출 연체 확률 낮아지는 경향 존재.

**ICE(Individual Conditional Expectation) plot(왼 전체/ 우~1.2)**

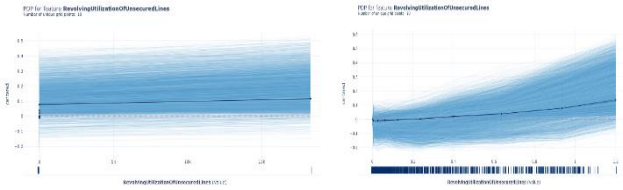

- 개별 선들이 큰 변화를 보이지 않고 대부분의 샘플들이 유사한 패턴을 보임. 다만 신용한도 총합 대비 신용 대출의 비율이 120%가 될 때까지 값이 높아질수록 비교적 연체할 확률이 더 높게 나타나는 고객들이 존재하기 때문에 이들에 대한 추가적인 분석이나 정책 수정이 필요.

## ● 약한 상관관계를 가지는 변수 해석

- 부동산 및 할부대출을 제외한 신용한도 내로 받은 융자의 총 잔액을 신용 한도 합계로 나눈 비율과 대출자의 나이 간 상관관계 확인

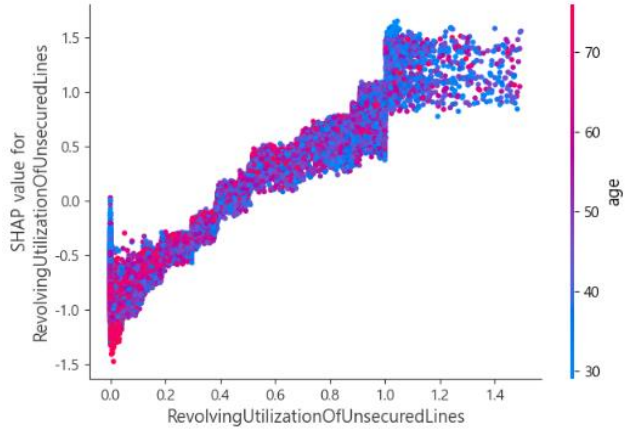


- 신용한도 총합 대비 신용 대출의 비율이 증가할수록 연체 가능성이 높아짐.
- 신용한도 총합 대비 신용 대출의 비율이 0.4 이상일 때부터 연체 가능성이 늘어나는 경향 존재.
- 특히 1 이상일 때 신용한도 총합 대비 신용 대출의 비율이 증가하고 나이가 작아질수록 대출 위험성은 늘어남.
- 신용한도 총합 대비 신용 대출의 비율이 0일 때 대체적으로 연체 가능성은 낮은 편이며 나이가 많을 때 연체 가능성은 더 낮았음.
- 신용한도 총합 대비 신용 대출의 비율이 0.4 이하일 땐 나이가 많다면 연체 대출 가능성이 낮았고, 0.8 이상일 땐 나이가 적다면 연체 가능성이 늘어남.
- 특히 1을 기점으로 나이가 적은 사람들의 비중이 늘어나면 연체 가능성이 급격히 증가.

→ **신용한도 총합 대비 신용 대출의 비율이 적고 나이가 많은 경우 안정적인 소득과 보수적인 신용 사용 습관으로 인해 연체 가능성이 낮아지는 것으로 추측.**

→ **신용한도 총합 대비 신용 대출의 비율이 1 이상이면서 나이가 적은 경우 연체율을 고려해 위험 고객 분류를 고려.**

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 대출자의 나이

**목표 플롯(Target plot)**

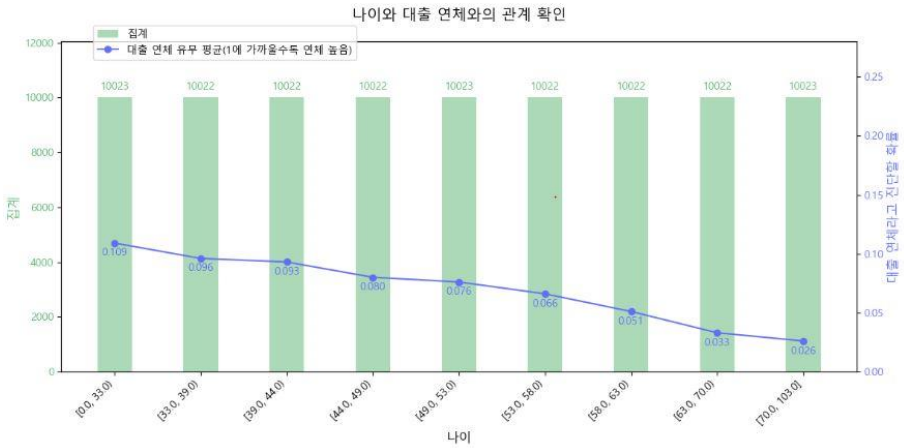


- 나이가 줄어가면서 대출을 연체할 확률이 감소하는 추세.

**예측 분포 플롯(Prediction distribution plot)**

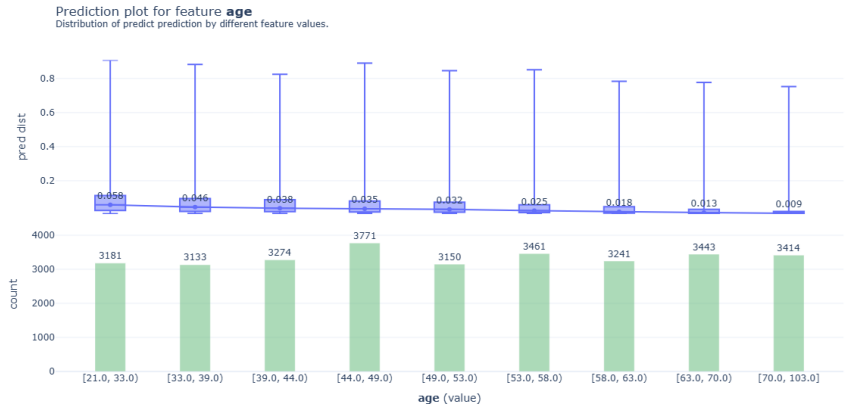


- 예측모델은 학습 데이터와 비슷한 추이로 예측해 실제 데이터 패턴을 잘 학습한 것으로 추정.

- 대출자의 나이

**PDP (전체)**

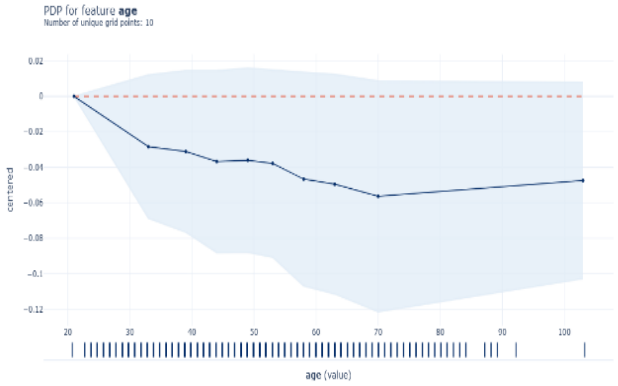


- 30세 즈음 급격히 연체 가능성이 떨어짐
- 70세 즈음까지 나이가 늘어날수록 대출을 연체하지 않을 확률 상승

  → **70세를 기점으로 고령자들이 대출을 받는 비율이 낮아지는 요인을 확인해볼 필요가 있어 보임**

- 70세 즈음을 전후로 대출을 연체하지 않을 확률이 늘어나다가 감소. 이 때부터 신뢰구간이 넓어지는 것으로 보아 데이터를 추가적으로 수집할 필요가 있음

  → **고령자 그룹에 대한 대출 정책 검토가 필요**

**ICE 플롯 (전체)**

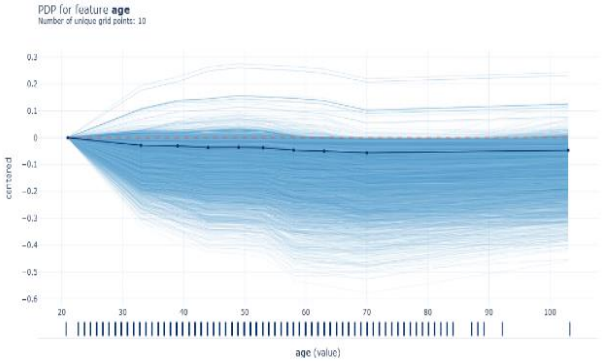


- 예측결과 30세부터 70세까지 나이가 들수록 대출을 연체할 확률이 떨어지며 다른 나이대에 비해 나이 변수가 영향을 미침
- 패턴을 보이는 데이터 일부 존재

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 대출자의 나이와 부동산 및 할부대출을 제외한 신용한도 내로 받은 융자의 총 잔액을 신용 한도 합계로 나눈 비율 간 상관관계 확인

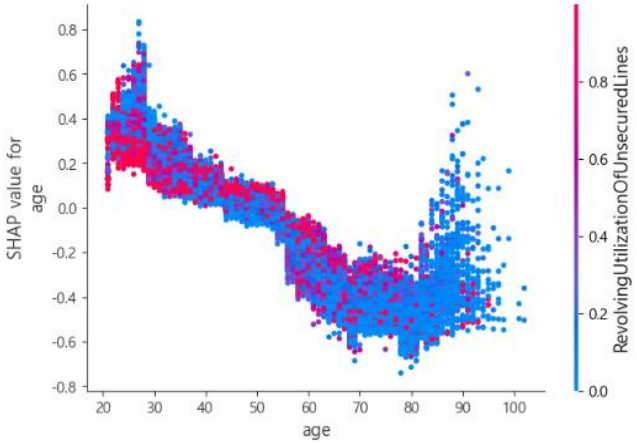


- 대출자의 나이가 늘어나고 신용한도 총합 대비 신용 대출의 비율이 작아질 때 70세까지 대출 연체 가능성이 낮아지는 경향 존재.
- 50대 구간은 나이에 따른 연체 가능성 변화가 크지 않음.
- 80세 이후에는 신용한도 총합 대비 신용 대출의 비율이 작을 때 오히려 연체 가능성이 급격하게 증가하는 경향이 있음.

→ **대출자의 나이가 많아지면서 대출을 적절히 관리하는 것으로 추측.**

→ **70세 이상일 경우 소득감소, 건강문제 등 경제적 불확실성으로 인해 대출 연체 감소세가 줄어드는 것으로 추측.**

→ **70세 이후신용한도 총합 대비 신용 대출의 비율이 작아도 연체 가능성이 급격하게 상승할 수 있기 때문에 심사에 주의를 기울일 필요가 있음.**

→ **50대에서는 나이가 아닌 다른 변수가 연체 가능성에 영향을 미칠 것으로 예상.**

- 대출자의 나이와 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 빌린 횟수 간 상관관계 확인

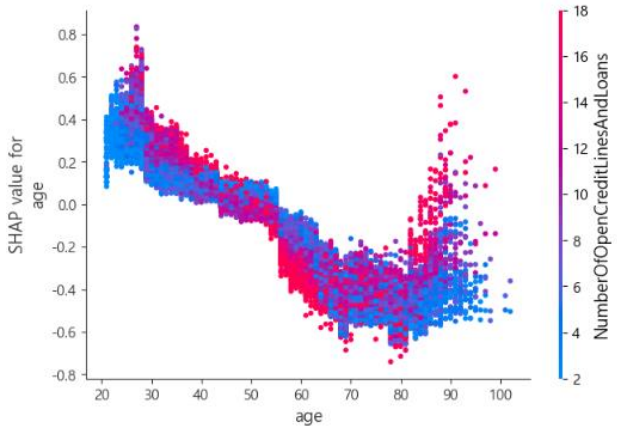


- 45~65세 구간대에 할부 대출 및 신용건수가 적을 때 다른 나이 구간대에 비해 대출 연체 가능성이 늘어나는 경향이 나타남.

→ **할부 대출이나 신용 대출의 종류에 따라 신용카드 한도가 적거나, 할부 대출이 부족해서 현금 흐름이 불안해 이런 차이가 발생하는 것인지 확인해 볼 필요가 있음.**

→ **연체 가능성이 신용 계좌 수 때문인지, 특정 대출 상품 때문인지 추가적으로 분석할 필요가 있음.**

→ **해당 분석 결과를 심사기준에 반영하고 대출 상품을 권유할 때 활용해 추가적인 상품을 제공하면서 연체 가능성을 줄일 수 있는지 검토해볼 필요가 있음.**

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율

**목표 플롯(Target plot)**

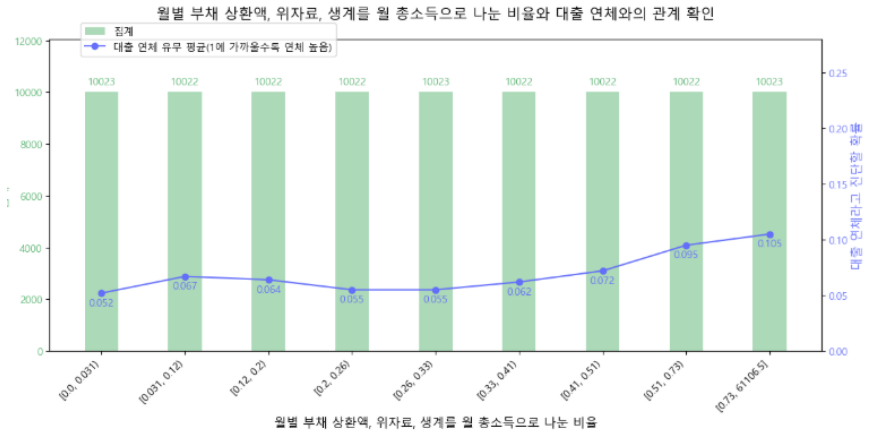


- 수입 대비 월 지출 비율이 커질수록 대출 연체 가능성은 상승하는 기조를 보임.
- 하지만 0.25(25%)까지는 하락하는 추세를 보임. 이 구간은 연체 가능성과 상관관계가 낮아 보임.
- 41~51, 51~73구간에 연체 가능성이 급격히 상승해 이 구간의 특성을 비교분석 할 필요가 있음.

**예측 분포 플롯(Prediction distribution plot)**

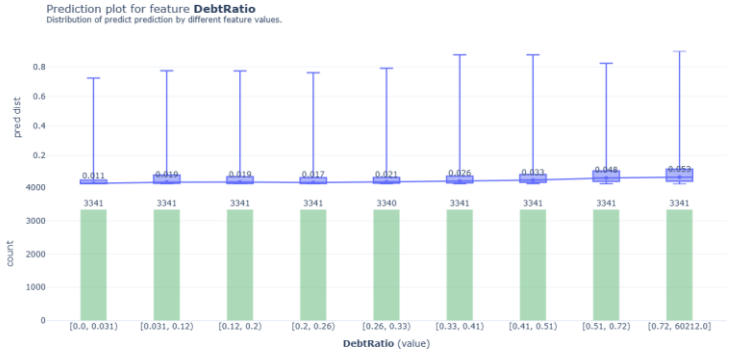


- 예측모델은 학습 데이터와 비슷한 추이로 예측해 실제 데이터 패턴을 잘 학습한 것으로 추정.

- 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율

**PDP(전체)**

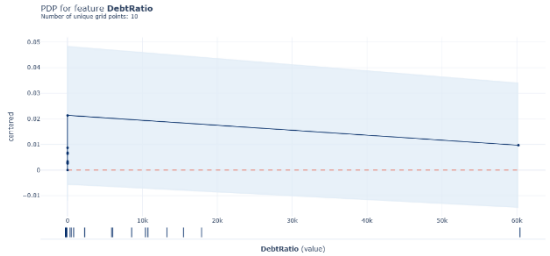


- 0을 초과할 때 부터 월 지출 비율이 높아질수록 대출 연체 확률 감소.

**ICE 플롯(전체)**

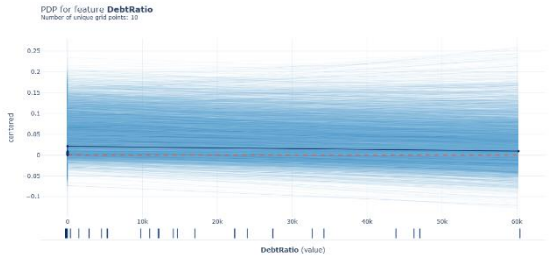


- 전체구간에 데이터가 고르게 분포해 모델의 예측값이 안정적인 것으로 보임.

**ICE 플롯(~1.2(120%))**

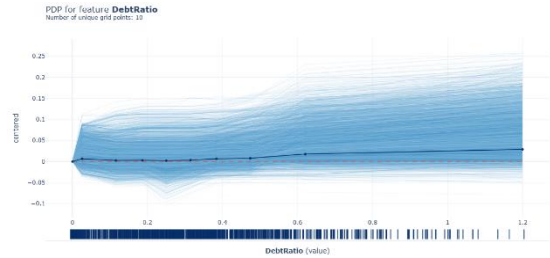


- 0~0.5사이에 많은 데이터가 분포되어 있으며 예측값이 안정적이지만 그 이후로는 신뢰구간이 넓어지며 예측값 변동성이 커짐.
- 또한 일부 0.2이후부터 0.7까지 급격히 올라가는 패턴이 보임.
- 그 이후부터는 완만하게 상승하는 추세.

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율과 부동산 및 할부대출을 제외한 신용한도 내로 받은 융자의 총 잔액을 신용 한도 합계로 나눈 비율 간 상관관계 확인

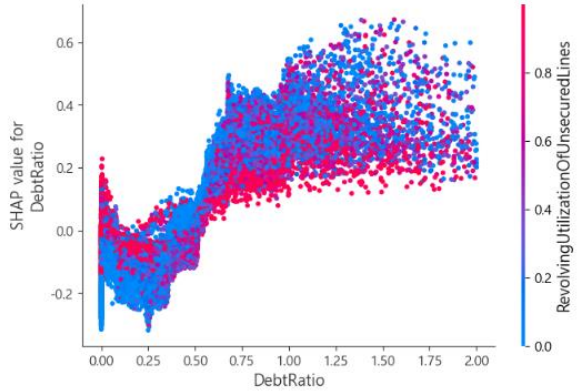


- 월 부채 비율이 0.2(20%) 이상이 되면서 연체 가능성이 증가하는 경향을 보임.
- 월 부채 비율이 0.2(20%)일 때부터 0.75인 구간에서 신용한도 총합 대비 신용 대출의 비율이 낮아도 전체 비율이 높아지면 연체가능성이 증가하는 경향을 보임.
- 월 부채 비율이 0일 땐 신용한도 종합 대비 신용 대출의 비율에 따라 영향을 크게 받는 것으로 보임.

→ **부채 비율이 증가하면 신용한도 종합 대비 신용 대출의 비율이 낮아도 연체가능성이 높아질 수 있기 때문에 부채 비율을 중심으로 리스크 관리를 수행할 필요가 있음.**

- 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율과 월 소득 간 상관관계 확인

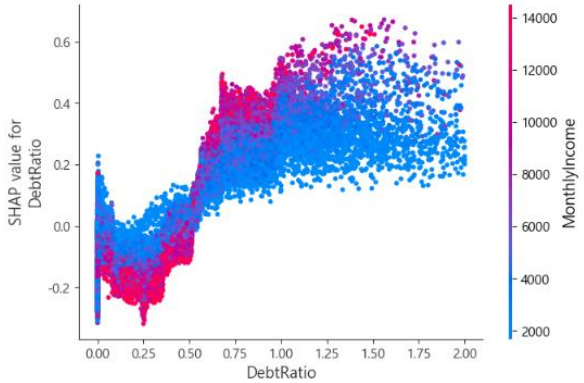


- 월 부채 비율이 0.5 이전 구간과 이후 구간으로 나눠 이전 구간에는 월 부채 비율이 낮고 월 수입이 많을 때 연체 가능성이 낮아지는 경향이 존재함.
- 0.5 이후 구간에는 월 수입이 많을 때 반대로 연체 가능성이 높아짐.

→ **고소득이더라도 부채비율이 많다면 연체 위험 가능성이 높아지기 때문에 대출 심사를 강화하고 대출 한도를 제한할 필요가 있음**

- 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율과 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용 카드)을 빌린 횟수 간 상관관계 확인

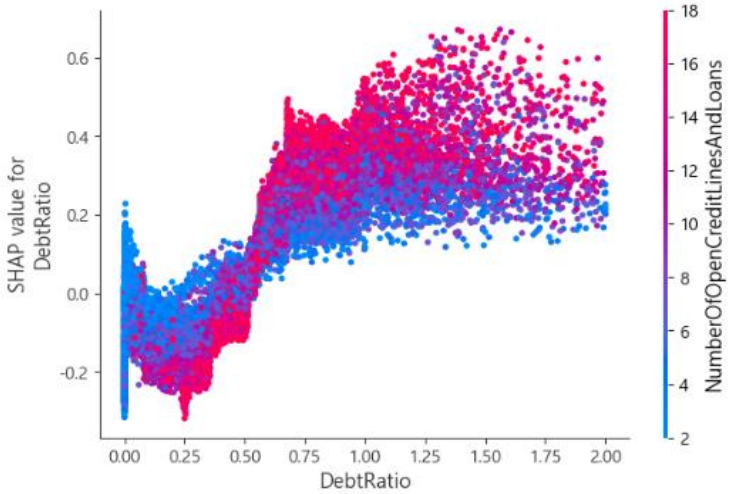


- 월 부채 비율이 0.5 이전과 이후로 나뉘어 연체 가능성이 달라짐.
- 월 부채 비율이 많고 할부 대출 및 신용 대출 횟수가 많을 때 연체 가능성은 늘어남.
- 월 부채 비율 0.5 이후에는 할부 대출 및 신용 대출 건수가 많은 사람이 상당량 차지.
- 월 부채 비율이 0일 때 할부 대출 및 신용 대출 횟수가 적어도 연체 가능성이 높거나 낮을 수 있음.

→ **월 부채 비율 0.5 이후에 할부 대출 및 신용 대출 건수가 많은 사람이 많기 때문에 부채 비율이 높아질 수록 신용계좌 수가 많은 사람들의 비율이 증가하는 것으로 보임.**

→ **월 부채 비율이 0인 구간에서 할부 대출 및 운용 대출횟수 외에 영향을 미치는 추가적인 변수를 확인할 필요가 있음.**

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 대출자의 월 수입

**목표 플롯(Target plot)**

- 기존에는 월 수입이 높을수록 연체 가능성이 높아지는 추세.

**예측 분포 플롯(Prediction distribution plot)**

- 예측모델은 월 수입이 올라갈수록 연체 가능성이 떨어지는 추세.
- 월 수입은 현재 모델에서 패턴이 충분히 반영되지 않음.

- 대출자의 월 수입

**PDP(전체)**

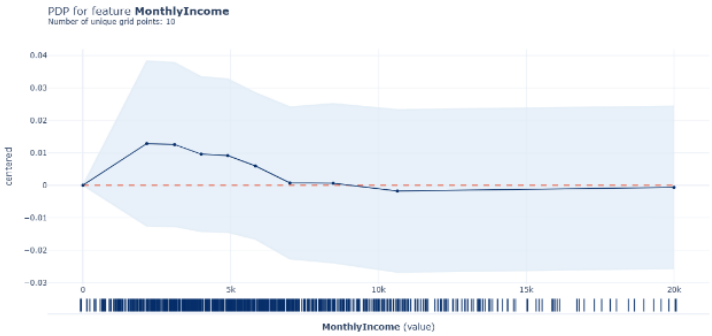


- 월수입이 6000달러까지 증가할 때 대출 연체 가능성이 하락하는 경향이 있음.
- 소득이 낮을수록 연체 가능성이 상대적으로 높은 편.
- 소득이 6천달러 이상일 때 미치는 영향은 크지 않음.

**ICE 플롯(전체)**

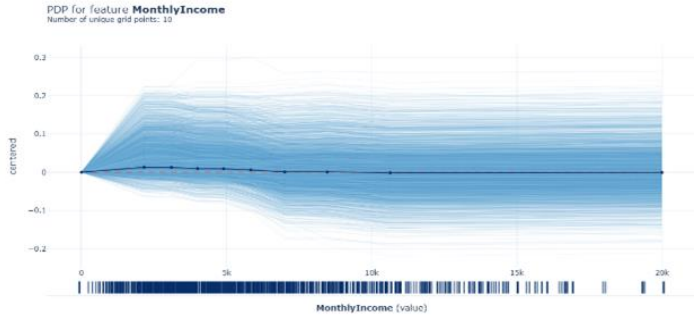


- 다른 패턴은 보이지 않음.

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 월 수입과 월별 부채 상환액, 위자료, 생계를 월 총소득으로 나눈 비율 간 상관관계 확인

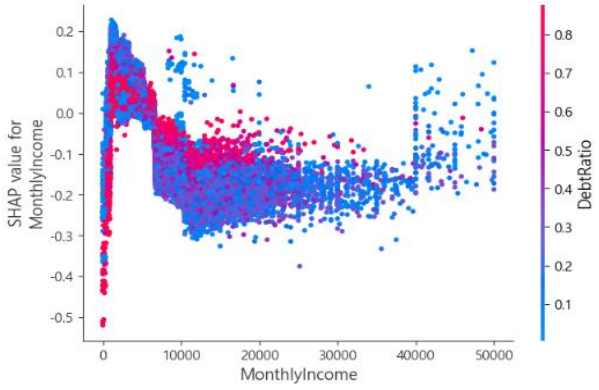


- 월 부채 비율이 0.5 이전 구간과 이후 구간으로 나눠 이전 구간에는 월 부채 비율이 낮고 월 수입이 많을 때 연체 가능성이 낮아지는 경향이 존재함.
- 0.5 이후 구간에는 5000~20000의 소득을 가지고 있을 때 소득이 증가해도 연체 가능성이 일정하게 유지되는 패턴 존재.

→ **5000~20000 구간의 소득을 가지고 있을 때 소득이 증가해도 연체 가능성이 일정하게 유지되는 패턴은 소득이 증가하면서 금리로 인한 부채 부담이 증가하거나 추가적인 대출을 받는 문제들로 인한 것이라 추측.**

→ **소득이 높아진다고 연체 가능성이 낮아진다고 보장할 수 없기 때문에 해당 구간에서 추가적인 심사 필요.**

- 월 수입과 할부 대출(한도 대출이나 자동차 대출, 주택담보 대출)과 신용 대출(신용카드)을 빌린 횟수 간 상관관계 확인

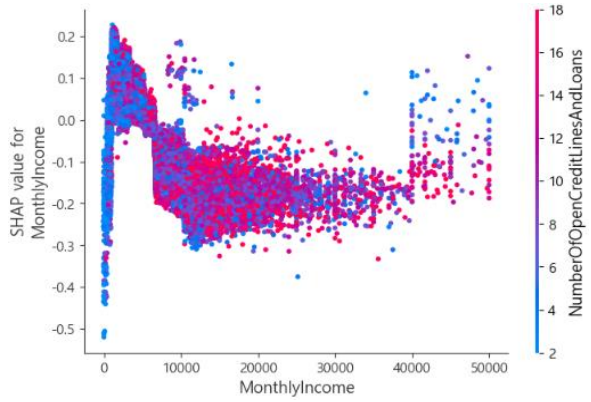


- 월 소득이 0에 가깝고 할부 대출 및 신용 대출 건수도 적을 때 상당히 넓은 분포를 보임.

  → 해당 구간에서는 다른 변수가 연체 가능성을 예측하는데 관여할 것으로 예상. 기존의 데이터베이스로는 해석이 불가해 새로운 금융 데이터 변수를 생성할 필요가 있음.

- 대출자를 제외한 부양가족 수

**목표 플롯(Target plot)**

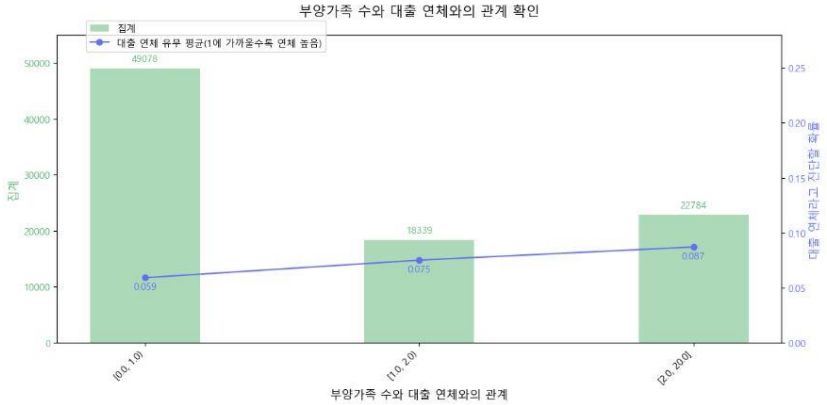


- 대체적으로 부양가족수가 늘어날수록 대출 연체 가능성이 늘어남.

**예측 분포 플롯(Prediction distribution plot)**

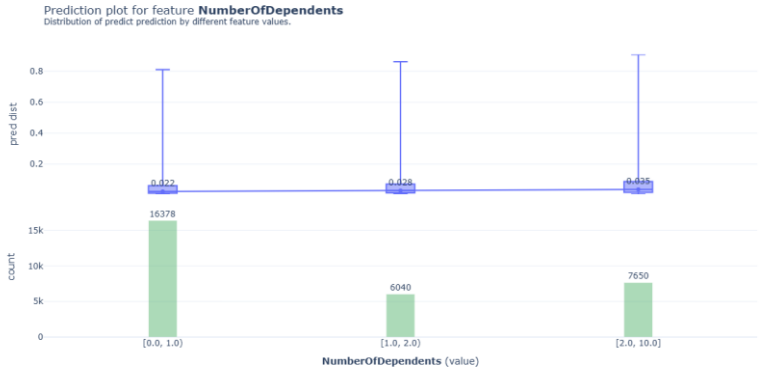


- 예측모델은 학습 데이터와 비슷한 추이로 예측해 실제 데이터 패턴을 잘 학습한 것으로 추정.

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

- 대출자를 제외한 부양가족 수

**PDP(전체)**

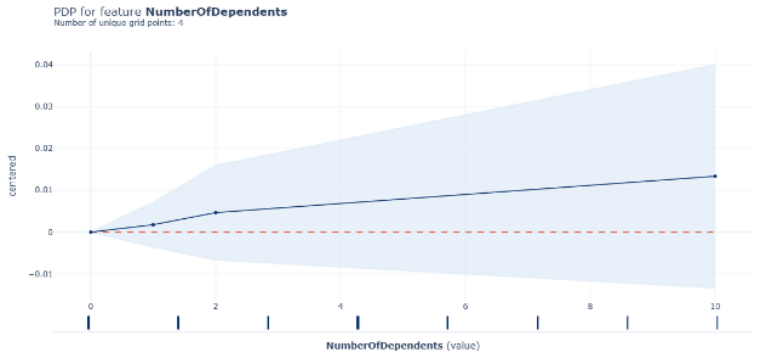


- 대체적으로 부양가족 수가 늘어나면서 대출 연체 가능성도 증가.
- 부양가족 수가 3명 이상일 때 부터  부양가족 수가 늘어날수록 대출 연체 가능성이 급격하게 늘어남.

**ICE 플롯(전체)**

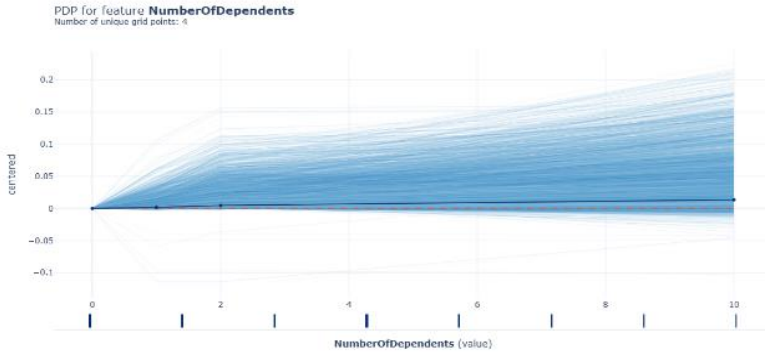


- 다른 패턴은 보이지 않음.

- 대출자를 제외한 부양가족 수와 부동산 및 할부대출을 제외한 신용한도 내로 받은 융자의 총 잔액을 신용 한도 합계로 나눈 비율 간 상관관계 확인

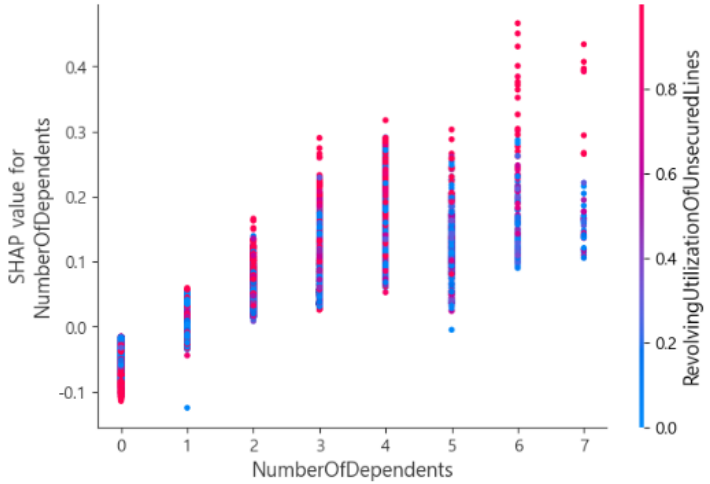


- 부양가족 수와 신용한도 총합 대비 신용 대출의 비율이 높아질수록 연체 확률 증가
  - → 부양가족이 늘어남에 따라 생활비 등의 지출 증가로 연체 위험성이 증가하는 것이라 추측
  - → 부양가족 수와 신용한도 종합 대비 신용 대출의 비율을 고려해 대출 리스크를 관리할 필요가 있음

# 대출 대상자 중 2년 내 대출금을 연체 가능성 여부를 예측하는 알고리즘 모델링

## Shap value 기준 변수 확인

훈련데이터셋 summary_plot

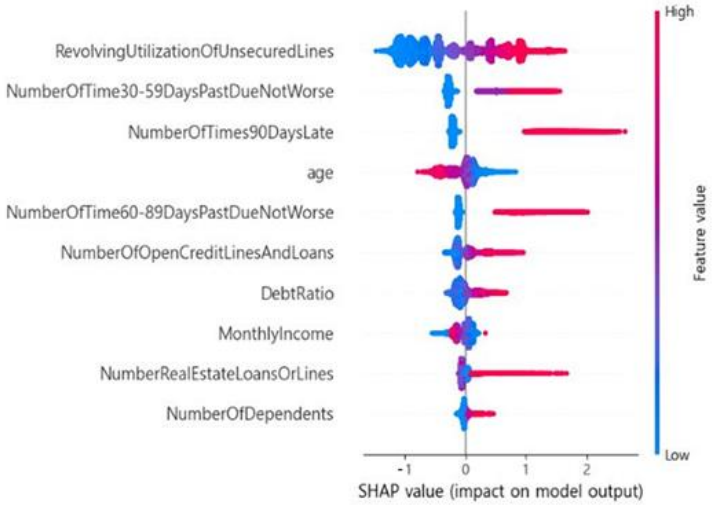


타겟데이터셋 summary_plot

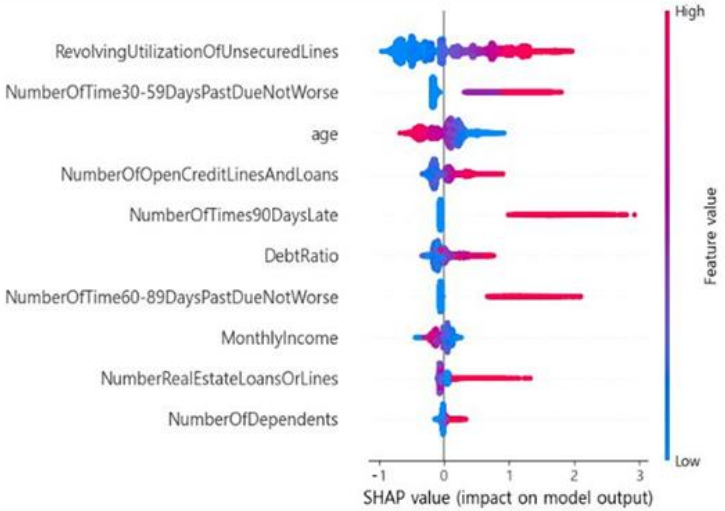


- 변수 평가 (공통사항)
  - 대출자의 나이는 값이 클 때 예측값을 감소시킴.
  - 대출자의 나이는 예측값에 음의 상관성을 미침.
  - 나이 외 변수들은 값이 클 때 예측값을 증가시킴.
  - 신용한도 총합 대비 신용카드 및 개인신용 대출 총 잔액의 비율과 30-59일간 연체 횟수를 중요변수로 간주.

- 변수 평가 (차이점)
  - 훈련 데이터에서는 90일 이상 연체 횟수의 중요도가 컸지만 실제 데이터에서는 중요도가 떨어짐.
  - 실제 데이터에서는 대출자가 할부 대출과 신용 대출(신용 카드)을 빌린 횟수를 더 중요하게 평가.

- 변수 변환(이진화)
  - 90일간 연체여부로 이진화를 고려했지만 기존 모델의 모델 해석 시 1.5 미만 초과로 구분해 모델링을 수행해 의미가 없을 것으로 추측.

- 변수 삭제 고려
  - 90일 변수를 제외하고 모델링 수행.
  - 결과: 변수삭제 전 ROC AUC score 0.855에서 이후 0.846으로 감소.

# 대출 대상자 중 2년 내 대출금을 90일 이상 연체할 가능성이 있는지 여부를 예측하는 알고리즘 모델링

## 결론

| | |
|---|---|
| 심사 기준에 따른 인사이트 | 90일 이상 연체 횟수가 1 이상일 때 위험군으로 분류 고려.<br>90일 이상 연체 횟수가 적지만 30~59일 연체 횟수가 많은 고객과 90일 이상 연체 횟수가 많지만 30~59일 연체 횟수가 적은 고객으로 나눠 위험 관리.<br><br>60~89 이상 연체 횟수가 1 이상일 때 위험군으로 분류 고려.<br>60~89 이상 연체 횟수가 5 이상일 때 연체를 갚을 수 있는 능력이 부족한 것으로 간주. 해당 고객의 특성을 파악하고 신규 고객들이 비슷한 패턴을 보일 때 리스크 관리에 활용.<br><br>할부 대출 및 신용 대출을 빌린 횟수가 10 미만일 때와 10 이상일 때로 나눠 위험 관리.<br>부동산 대출 건수 3~4건, 5~9건, 구간으로 나눠 위험 관리.<br>30~59일 연체 경험이 있을 때 신용대출 비율이 0.5 이상인 사람들을 대상으로 마이데이터를 활용해 신용카드로 불법 현금화를 하고있는 고객을 분류하고 패턴 파악 후 리스크 관리에 사용.<br>90일 이상 연체 경험이 있을 때 신용 대출의 비율이 0.5 이상인 사람들을 대상으로 마이데이터를 활용해 신용카드로 불법 현금화하는 고객을 분류하고 패턴을 파악해 리스크 관리에 사용 .<br><br>할부 대출 및 신용 대출 건수가 10 이상일 때 월 지출 비율이 0.4 이상이라면 연체율을 고려해 위험 관리.<br>부동산 담보 대출 횟수가 3~4일 때 월 지출 비율이 0.4~0.5인 고객들을 대상으로 신용 우량 고객 분류 검토.<br>60~89일 연체 횟수 1~3일 때 신용한도 대비 대출의 비율이 낮은 고객은 심사 시 주의하고 현금융통 의심.<br><br>대출 심사에서 신용한도 총합 대비 신용 대출 비율이 0.4 이상일 때 구간 나눠 신용 평가.<br><br>30~59일 이상 연체 횟수가 1~4회일 때 위험군으로 분류 고려.<br>신용한도 총합 대비 신용 대출의 비율이 1 이상이면서 나이가 적으면 연체율을 고려해 위험 고객 분류 고려.<br>대출자의 나이가 70세 이상일 경우 신용 대출 비율이 낮아도 심사에 주의.<br>신용한도 종합 대비 신용 대출 비율이 낮아도 월 부채비율을 중심으로 위험 관리 수행.<br><br>고소득이라도 부채비율이 많으면 대출 심사를 강화하고 대출 한도를 제한.<br>5k~20k 구간 내 소득을 보유하고 있을 때 소득이 증가해도 소득 구간별 추가 심사 필요.<br><br>부양가족 수와 신용한도 총합 대비 신용 대출의 비율을 고려해 대출 위험 관리. |
| 상품 제안에 따른 인사이트 | 대출자가 50세 이상일 때 할부 대출 및 신용대출 건수가 10 미만이라면 추가적인 관심 대출상품 제시.<br>할부 대출이나 신용 대출의 종류에 따라 신용카드 한도가 적거나 할부 대출이 부족해서 연체 여부에 차이가 있는지 추가 분석하고 이를 바탕으로 추가적인 상품 푸쉬. |
| 기타 인사이트 | 신용한도 총합 대비 신용 대출 비율이 120%가 될 때까지 값이 높아질수록 가용현금 비율이 높아지지만, 연체 확률이 늘어나 원인 규명을 위한 추가적인 분석 필요.<br>월 부채비율이 0인 구간에서 할부 대출 및 신용 대출 횟수 외에 영향을 미치는 추가적인 변수 확인.<br>월 소득이 0에 가깝고 할부 대출 및 신용대출 건수도 적을 때 영향을 미치는 요인 확인 필요. |